Programación 1

Tema 10

Caracteres y cadenas de caracteres

Escuela de
Ingeniería y Arquitectura
Universidad Zaragoza

Índice

- Caracteres
- Cadenas de caracteres

El tipo carácter

- Tipos carácter
  - **Dominio** de valores
  - **Representación** de los valores
    - Externa (en C++)
    - Interna (en la memoria del computador)
  - **Operadores** asociados

Caracteres
Dominio de valores

Fuente: Wikimedia Commons contributors (awdean1), 'File:Brother typewriter by awdean1.jpg', *Wikimedia Commons, the free media repository,* 2016, <https://commons.wikimedia.org/w/index.php?title=File:Brother_typewriter_by_awdean1.jpg>

Caracteres

Posible dominio de valores

- Letras mayúsculas del alfabeto inglés
- Letras minúsculas del alfabeto inglés
- Dígitos
- Signos de puntuación
- Signos matemáticos
- Letras con diacríticos (alfabetos latinos occidentales)
- Letras alfabetos centro-europeos
- Letras alfabeto griego
- Letras alfabeto cirílico
- Letras alfabetos asiáticos

Caracteres
Unicode

- Estándar de codificación de caracteres
- Dominio de valores incluye:
  - Alfabeto latino: A a B b C c D d E e F f G g H h I i J j K k L l M m N n …
  - Alfabeto griego: α β γ δ ε ζ η θ ι κ λ μ ν ξ ο π ρ ς σ τ υ φ χ ω …
  - Alfabeto cirílico: б в г ж з и й к л м н п с т у ф х ц ч шщ ъ ы ь …
  - Alfabetos centro-europeos: Á â ă ä Ĺ ć ç č é ę ë ě í î ď đ ń ň ó ô ŕ …
  - Alfabeto árabe: چ ژ گ ک ء آ أ ؤ إ ئ ا ب ة ت ث ج ح خ د س ص ع ل م و …
  - Alfabeto hebreo: א ב ג ד ה ו ז ח ט י כ ך ל מ ם נ ן ס ע פ ף צ ץ ק ר ש ת …
  - Alfabetos asiáticos: 中文萬國碼際字出典フリ百科事典ィキペデ…
  - Símbolos: £ ₧ € № ¼ ½ ¾ ⅐ ← ↑ ↗ ⇨ ∀ ∂ ∃ ∄ ⌘ ⌦ …
  - Emoji: ☺ 😉 😀 😁 😱 💀 👽 😸 🕺 👋 👶 👧 🏄 🌵 💻 👄 🚂 ⌨ 🦵 🦑 …

Caracteres en C++

- Varios tipos
  - **`char`**
    - 1 *byte* (8 bits) en MinGW y GNU GCC
  - **`wchar_t`**
    - 2 *bytes* (16 bits) en MinGW y GNU GCC
  - **`char16_t`**
    - 2 *bytes* (16 bits), estándar
  - **`char32_t`**
    - 4 *bytes* (32 bits), estándar

Caracteres

- **char**
- Dominio de valores
  - 95 caracteres
    - Letras del alfabeto inglés
    - Dígitos
    - Signos de puntuación
    - Otros símbolos
  - 33 *caracteres* de control

	0	@	P	`	p
!	1	A	Q	a	q
"	2	B	R	b	r
#	3	C	S	c	s
$	4	D	T	d	t
%	5	E	U	e	u
&	6	F	V	f	v
'	7	G	W	g	w
(	8	H	X	h	x
)	9	I	Y	i	y
*	:	J	Z	j	z
+	;	K	[	k	{
,	<	L	\	l	|
-	=	M	]	m	}
.	>	N	^	n	~
/	?	O	_	o	

Caracteres

- Representación externa en C++
  - 'a' 'A' 'b' 'B' 'z' 'Z'
  - '0' '1' '2' '3' '4' '5' '6' '7' '8' '9'
  - '+' '-' '*' '/' '<' '=' '>'
  - '(' ')' '[' ']' '{' '}'
  - '#' '$' '%' '&' ',' '.' ':' ';' '!' '?' '@' '^' '_' '`' '|' '~' '¬'
  - '"' '\'' '\\'

Representación interna

- Codificación arbitraria en binario
  - Código ASCII
    - *American Standard Code for Information Interchange*
    - Estandarizada por la American Standards Association en 1963
- Ejemplo: 'A' se codifica con
  - la secuencia binaria 0100 0001
  - el código numérico 65

Representación interna

Código	Carácter	Código	Carácter	Código	Carácter	Código	Carácter	Código	Carácter	Código	Carácter	Código	Carácter	Código	Carácter
0	NUL	16	DLE	32		48	0	64	@	80	P	96	`	112	p
1	SOH	17	DC1	33	!	49	1	65	A	81	Q	97	a	113	q
2	STX	18	DC2	34	"	50	2	66	B	82	R	98	b	114	r
3	ETX	19	DC3	35	#	51	3	67	C	83	S	99	c	115	s
4	EOT	20	DC4	36	$	52	4	68	D	84	T	100	d	116	t
5	ENQ	21	NAK	37	%	53	5	69	E	85	U	101	e	117	u
6	ACK	22	SYN	38	&	54	6	70	F	86	V	102	f	118	v
7	BEL	23	ETB	39	'	55	7	71	G	87	W	103	g	119	w
8	BS	24	CAN	40	(	56	8	72	H	88	X	104	h	120	x
9	HT	25	EM	41	)	57	9	73	I	89	Y	105	i	121	y
10	LF	26	SUB	42	*	58	:	74	J	90	Z	106	j	122	z
11	VT	27	ESC	43	+	59	;	75	K	91	[	107	k	123	{
12	FF	28	FS	44	,	60	<	76	L	92	\	108	l	124	|
13	CR	29	GS	45	-	61	=	77	M	93	]	109	m	125	}
14	SO	30	RS	46	.	62	>	78	N	94	^	110	n	126	~
15	SI	31	US	47	/	63	?	79	O	95	_	111	o	127	DEL

Otras codificaciones de caracteres

- Longitud fija
  - 8 bits ⟶ 256 caracteres
    - Latin1 (ISO 8859-1), Latin0 (ISO 8859-15), Windows-1252
    - Página de códigos 850
  - 16 bits ⟶ 65 536 caracteres
    - UCS-2: 2-byte Universal Character Set (obsoleto)
  - 32 bits ⟶ 4 294 967 296 caracteres
    - UCS-4, UTF-32
- Longitud variable
  - UTF-8
  - UTF-16

El estándar Unicode

- Define 297 334 ***caracteres abstractos***
- Cada carácter abstracto se identifica de forma precisa por un entero único: ***punto de código*** (*code point*)
- Cada punto de código se puede codificar a través de distintas **codificaciones**:
  - UTF-8: 1, 2, 3 o 4 *bytes*
    - Compatible con los códigos ASCII de 7 bits
  - UTF-16: 2 o 4 *bytes*
  - UTF-32: 4 *bytes*
  - …

Problemas con las codificaciones

- Ejemplo 1:
  - Windows con Visual Studio Code utilizando como terminal PowerShell
- Ejemplo 2:
  - Linux con Visual Studio Code usando el terminal del SO

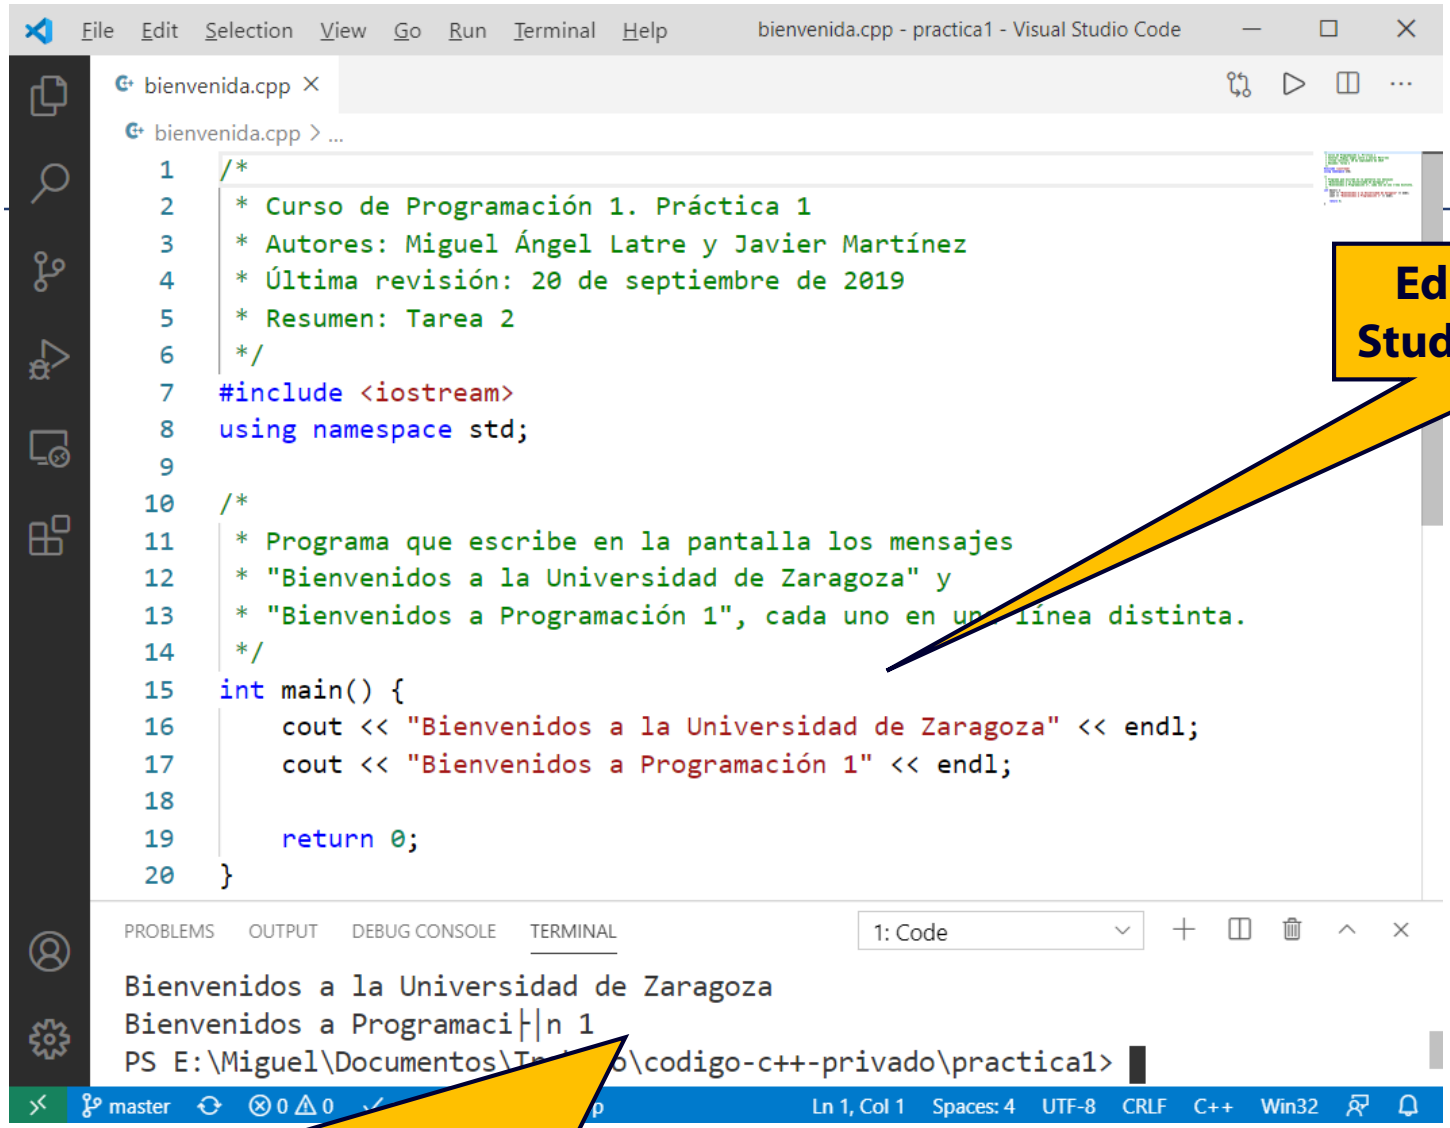

Editor de Visual Studio Code: UTF-8

Terminal (PowerShell o Símbolo de sistema de Windows): CP-850

Ejemplo. Carácter *ó*

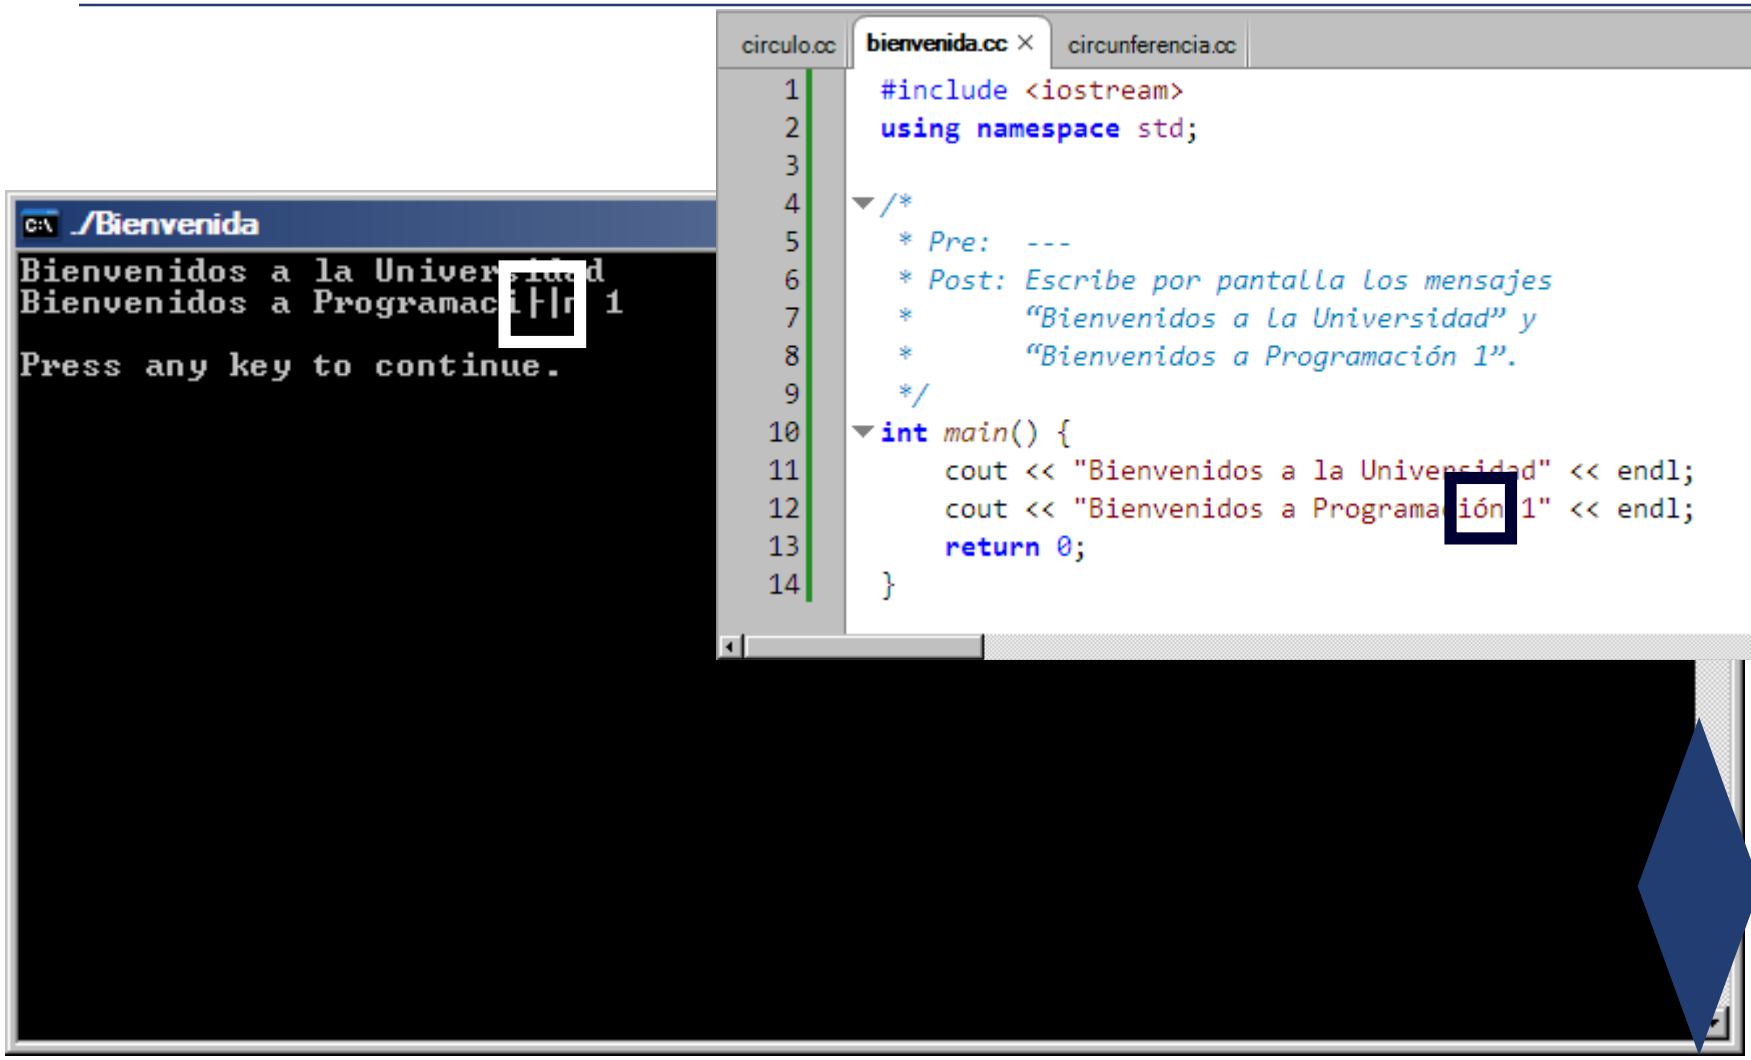

Carácter «ó»

- Unicode:
  - **«ó»**
    - **Descripción:** Letra latina O minúscula con acento agudo
    - **Punto de código:** U+00F3 (en decimal: 243)
    - **Codificación en UTF-8:** *bytes* 195 y 179

Página de códigos 850

128	Ç	129	ü	130	é	131	â	132	ä	133	à	134	å	135	ç
136	ê	137	ë	138	è	139	ï	140	î	141	ì	142	Ä	143	Å
144	É	145	æ	146	Æ	147	ô	148	ö	149	ò	150	û	151	ù
152	ÿ	153	Ö	154	Ü	155	ø	156	£	157	Ø	158	×	159	ƒ
160	á	161	í	162	ó	163	ú	164	ñ	165	Ñ	166	ª	167	º
168	¿	169	®	170	¬	171	½	172	¼	173	¡	174	«	175	»
176	▒	177	▒	178	▓	179	│	180	┤	181	Á	182	Â	183	À
184	©	185	╣	186	║	187	╗	188	╝	189	¢	190	¥	191	┐
192	└	193	┴	194	┬	195	├	196	─	197	┼	198	ã	199	Ã
200	╚	201	╔	202	╩	203	╦	204	╠	205	═	206	╬	207	¤
208	ð	209	Ð	210	Ê	211	Ë	212	È	213	ı	214	Í	215	Î
216	Ï	217	┘	218	┌	219	█	220	▄	221	¦	222	Ì	223	▀
224	Ó	225	ß	226	Ô	227	Ò	228	õ	229	Õ	230	µ	23	Þ
232	þ	233	Ú	234	Û	235	Ú	236	ý	237	Ý	238	¯	2	´
240		241	±	242	_	243	¾	244	¶	245	§	246	÷	24	¸
248	°	249	¨	250	·	251	¹	252	³	253	²	254	■	255	

Carácter «ó»

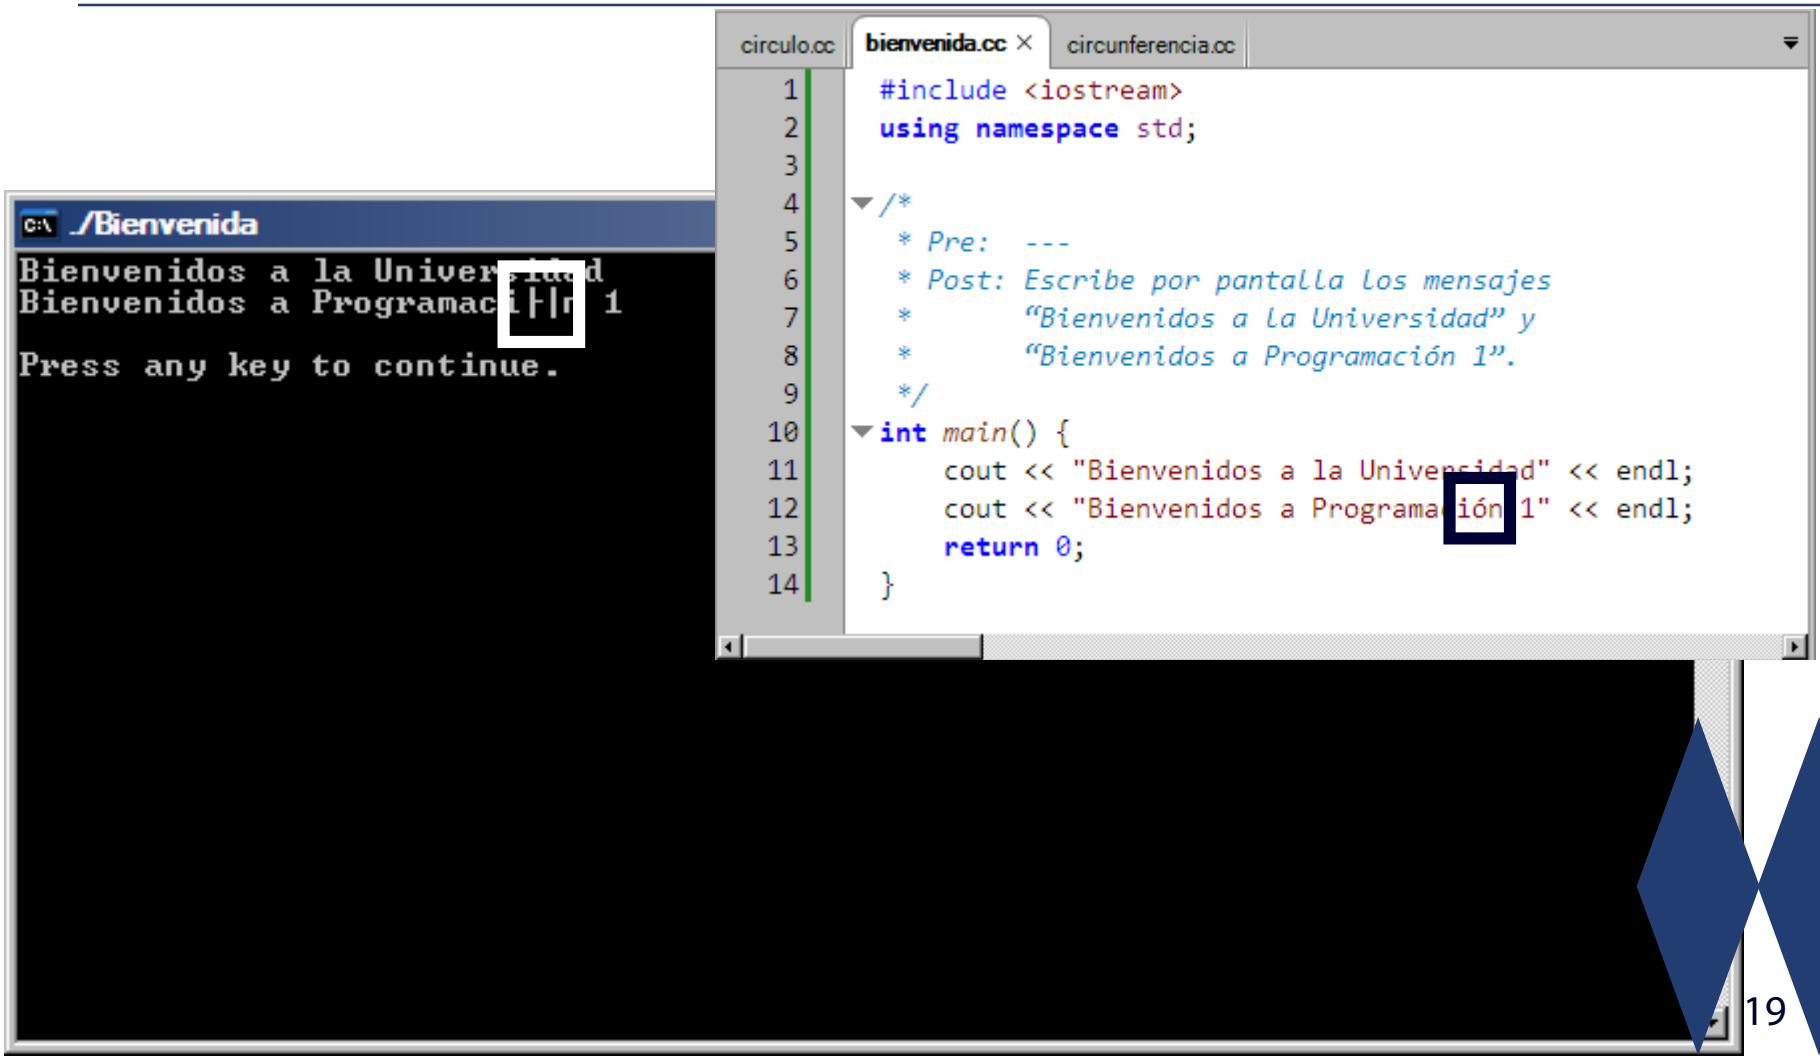
circulo.cc
bienvenida.cc
circunferencia.cc
1 #include <iostream>
2 using namespace std;
3
4 /*
5 * Pre: ---
6 * Post: Escribe por pantalla los mensajes
7 * "Bienvenidos a la Universidad" y
8 * "Bienvenidos a Programación 1".
9 */
10 int main() {
11 cout << "Bienvenidos a la Universidad" << endl;
12 cout << "Bienvenidos a Programación 1" << endl;
13 return 0;
14 }
./Bienvenida
Bienvenidos a la Universidad
Bienvenidos a Programación 1
Press any key to continue.

Problemas con las codificaciones

- Ejemplo 1:
  - Windows con Visual Studio Code utilizando PowerShell como terminal
- Ejemplo 2:
  - Linux con Visual Studio Code usando el terminal del SO

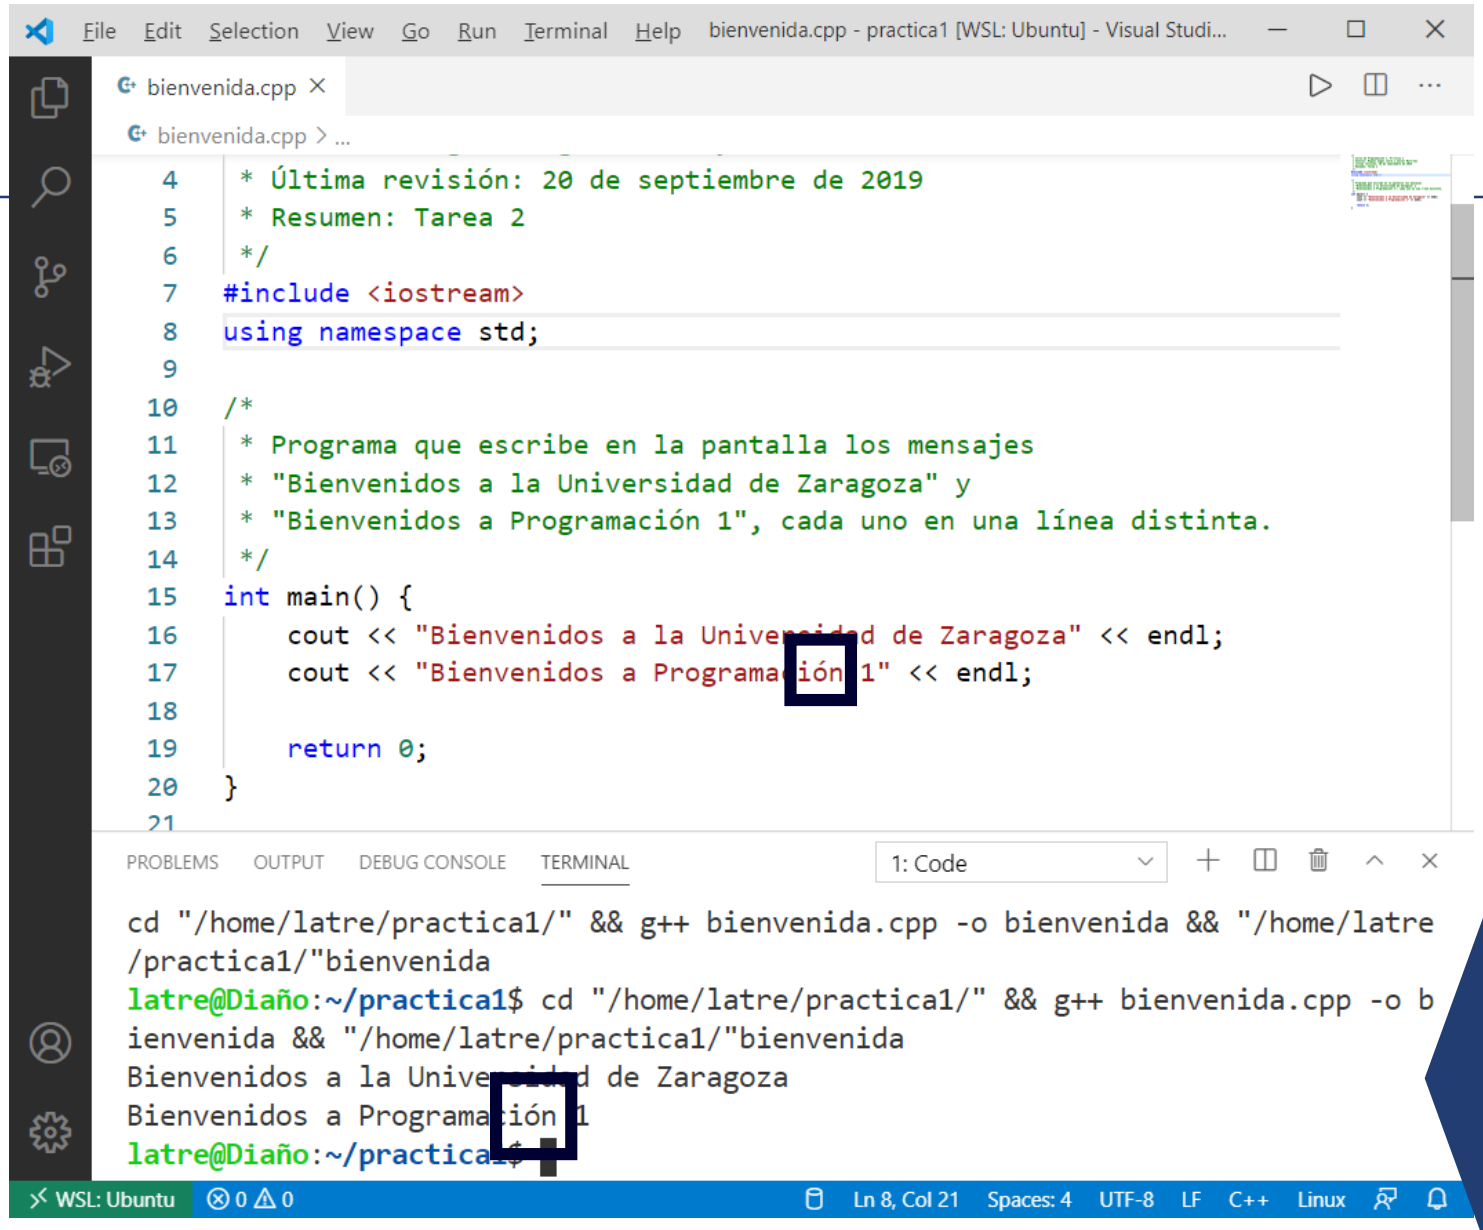
File Edit Selection View Go Run Terminal Help bienvenida.cpp - practica1 [WSL: Ubuntu] - Visual Studi...
bienvenida.cpp
bienvenida.cpp > ...
4 * Última revisión: 20 de septiembre de 2019
5 * Resumen: Tarea 2
6 */
7 #include <iostream>
8 using namespace std;
9
10 /*
11 * Programa que escribe en la pantalla los mensajes
12 * "Bienvenidos a la Universidad de Zaragoza" y
13 * "Bienvenidos a Programación 1", cada uno en una línea distinta.
14 */
15 int main() {
16 cout << "Bienvenidos a la Universidad de Zaragoza" << endl;
17 cout << "Bienvenidos a Programación 1" << endl;
18
19 return 0;
20 }
21
PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL
1: Code
cd "/home/latre/practica1/" && g++ bienvenida.cpp -o bienvenida && "/home/latre/practica1/"bienvenida
latre@Diaño:~/practica1$ cd "/home/latre/practica1/" && g++ bienvenida.cpp -o bienvenida && "/home/latre/practica1/"bienvenida
Bienvenidos a la Universidad de Zaragoza
Bienvenidos a Programación 1
latre@Diaño:~/practica1$
WSL: Ubuntu 0 0 Ln 8, Col 21 Spaces: 4 UTF-8 LF C++ Linux

Más información

- Joel Spolsky, «The Absolute Minimum Every Software Developer Absolutely, Positively Must Know About Unicode and Character Sets (No Excuses!)», *Joel on Software*, 8-10-2013.
  - https://www.joelonsoftware.com/2003/10/08/the-absolute-minimum-every-software-developer-absolutely-positively-must-know-about-unicode-and-character-sets-no-excuses/

Operadores asociados

- Los de los tipos enteros
  - Aritméticos: +, -, …
  - Relación: ==, !=, <, <=, >, >=
- Conversión con enteros pueden ser explícitas:
  - `int('A')` se evalúa como 65
  - `char(66)` se evalúa como 'B'

Propiedades

- Hay secuencias de caracteres con códigos consecutivos crecientes:
  - Mayúsculas del alfabeto inglés: ‘A’, ‘B’, ‘C’, … , ‘X’, ‘Y’ y ‘Z’
  - Minúsculas del alfabeto inglés : ‘a’, ‘b’, ‘c’, … , ‘x’, ‘y’ y ‘z’
  - Dígitos: ‘0’, ‘1’, ‘2’, ‘3’, ’4’, ’5’, ’6’, ‘7’, ‘8’ y ‘9’

Expresiones con caracteres

- `char c = 'E';`

1. `c == 'A'`
2. `c != 'e'`
3. `c >= 'A'`
4. `c <= 'Z'`
5. `c >= 'A' && c <= 'Z'`
6. `c >= 'a'`
7. `c <= 'z'`
8. `c >= 'a' && c <= 'z'`
9. `char(c + 1)`
10. `char(c + 32)`
11. `char(c - 'A' + 'a')`

65	A
66	B
67	C
68	D
69	E
70	F
71	G
72	H
73	I
74	J
75	K
76	L
77	M
78	N
79	O
80	P
81	Q
82	R
83	S
84	T
85	U
86	V
87	W
88	X
89	Y
90	Z

97	a
98	b
99	c
100	d
101	e
102	f
103	g
104	h
105	i
106	j
107	k
108	l
109	m
110	n
111	o
112	p
113	q
114	r
115	s
116	t
117	u
118	v
119	w
120	x
121	y
122	z

Biblioteca estándar <cctype>

- Character handling functions. This header declares a set of functions to classify and transform individual characters.
  - `isalnum`: Check if character is alphanumeric
  - `isalpha`: Check if character is alphabetic
  - `islower`: Check if character is lowercase letter
  - `isupper`: Check if character is uppercase letter
  - `isdigit`: Check if character is decimal digit
  - `isspace`: Check if character is a white-space
  - `tolower`: Convert uppercase letter to lowercase
  - `toupper`: Convert lowercase letter to uppercase

Fuente: «<cctype> (ctype.h)». *Cplusplus.com*. 2000–2017. https://cplusplus.com/reference/cctype/ (consultado el 29-10-2025)

Índice

- Caracteres
- Cadenas de caracteres

Cadenas de caracteres

- Secuencias de 0, 1 o más caracteres
- Representación literal entre comillas
  - `""`
  - `"A"`
  - `"Programación 1"`

Cadenas de caracteres

- Posibilidades de representación
  - Vector de datos de tipo **`char`** finalizadas con el carácter de código 0 (**NUL** o `'\0'`)
    - Conocidas como *null-terminated strings* o *C strings*.

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19
U	**n**	**i**	**z**	**a**	**r**	NUL	?	?	?	?	?	?	?	?	?	?	?	?	?

Cadenas de caracteres

- Posibilidades de representación
  - Vector de datos de tipo **`char`** finalizadas con el carácter de código 0 (**NUL** o **`'\0'`**)
    - Conocidas como *null-terminated strings* o *C strings*.
    - No trabajaremos con ellas en este curso
  - Clase predefinida **`string`**

Clase `string`

- Dominio de valores
  - Secuencias de 0, 1 o más caracteres
  - Longitud máxima de la secuencia limitada por la memoria disponible
- Representación externa
  - Secuencia de caracteres entre comillas
    - `""`
    - `"A"`
    - `"Programación 1"`

Clase `string`

- Representación interna
  - Objetos
  - En último término, un vector de datos de tipo **`char`**.
- Operaciones
  - Las definidas en el módulo predefinido `<string>` para la clase **`string`**:
    - https://cplusplus.com/reference/string/string/

Clase `string`
Operaciones

Operación	Operador o método
Asignación	`=`
Longitud de la cadena	`length()`
Acceso a caracteres	`[]` `at()`
Comparación	`compare()` `==` `!=` `<` `<=` `>` `>=`
Concatenación	`+` `+=`
Extracción de teclado	`>>`
Inserción en pantalla	`<<`

Clase string

Ejemplo 1: declaración, asignación y escritura en pantalla

```
#include <iostream>
#include <string>
using namespace std;


int main() {
    string nombre;
    nombre = "Miguel";
    cout << nombre << endl;
    return 0;
}
```

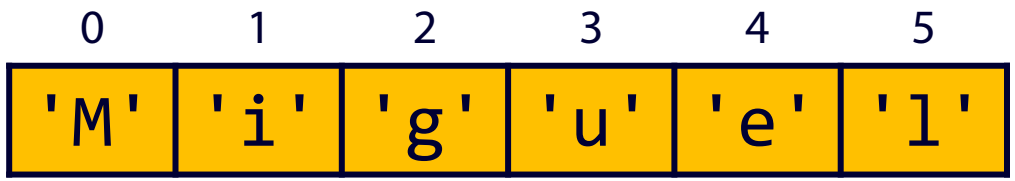

Clase string

Ejemplo 1[b]: declaración con inicialización y escritura en pantalla

```
#include <iostream>
#include <string>
using namespace std;


int main() {
    string nombre = "Miguel";
    cout << nombre << endl;
    return 0;
}
```

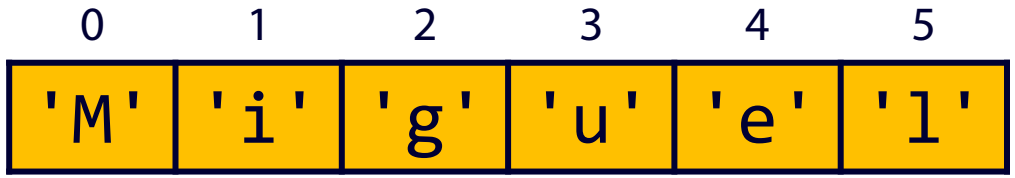

Clase `string`

Ejemplo 2: lectura de teclado y acceso a un carácter

```
#include <iostream>
#include <string>
using namespace std;

int main() {
    cout << "Escribe tu nombre de pila: ";
    string nombre;
    cin >> nombre;

    cout << "Hola, " << nombre << endl;
    cout << "Tu nombre empieza por la letra "
         << nombre[0] << "." << endl;
    return 0;
}
```

Clase `string`

Ejemplo 3: acceso a un carácter con el método «at()»

```
#include <iostream>
#include <string>
using namespace std;

int main() {
    cout << "Escribe tu nombre de pila: ";
    string nombre;
    cin >> nombre;

    cout << "Hola, " << nombre << endl;
    cout << "Tu nombre empieza por la letra "
         << nombre.at(0) << "." << endl;
    return 0;
}
```

Clase `string`

Ejemplo 4: «length()» y operadores de comparación

```
#include <iostream>
#include <string>
using namespace std;

int main() {
    cout << "Escribe tu nombre de pila: ";
    string nombre;
    cin >> nombre;
    cout << "Tu nombre tiene " << nombre.length() << " letras." << endl;
    if (nombre == "Miguel") {
        cout << "Te llamas como yo." << endl;
    } else if (nombre < "Miguel") {
        cout << "Tu nombre va alfabéticamente antes que el mío." << endl;
    } else {
        cout << "Tu nombre va alfabéticamente después del mío." << endl;
    }
    return 0;
}
```

Clase `string`

Ejemplo 5: concatenación

```
#include <iostream>
#include <string>
using namespace std;

int main() {
    string nombre, apellido;
    cout << "Escribe tu nombre de pila: ";
    cin >> nombre;
    cout << "Escribe tu primer apellido: ";
    cin >> apellido;

    string nombreCompleto = nombre + " " + apellido;

    cout << "Tu nombre completo es " << nombreCompleto << endl;
    return 0;
}
```

Vectores de cadenas de caracteres

```
/*
 * Pre:  1 ≤ mes ≤ 12
 * Post: Escribe en la pantalla el nombre (en
 *       mayúsculas) del mes correspondiente al valor del
 *       parámetro «mes».
 */
void escribirNombreMes(const unsigned mes) {
    const string NOMBRES_MES[NUM_MESES] = { "ENERO",
            "FEBRERO", "MARZO", "ABRIL", "MAYO", "JUNIO",
            "JULIO", "AGOSTO", "SEPTIEMBRE", "OCTUBRE",
            "NOVIEMBRE", "DICIEMBRE" };
    cout << NOMBRES_MES[mes - 1];
}
```

¿Cómo se puede estudiar este tema?

- Repasando estas transparencias
- Trabajando con el código de estas transparencias
  - https://github.com/prog1-eina/tema-10-cadenas
- Leyendo material adicional publicado en Moodle
- Trabajando con los problemas del tema